

Analisis Pembangunan Wilayah Indonesia

Kelompok 10

Muhammad Ilham Nurhakim (J0403251004)

Ahmad Maulana Abimanyu (J0403251017)

Muhamad Daud Ghifari (J0403251026)

Hanif Misbah (J0403251102)

Aditya Nugraha (J0403251112)

Caesarian Lanang Parizano Zaim (J0403251121)

2026-06-08

Contents

1	BAB I: PENDAHULUAN	2
1.1	Latar Belakang	2
1.2	Tujuan Analisis	2
2	BAB II: METODOLOGI	3
2.1	Dataset	3
2.2	Tools yang Digunakan	5
2.3	Metode Analisis	5
3	BAB III: HASIL DAN PEMBAHASAN	6
3.1	Statistika Deskriptif	6
3.2	Deteksi dan Penanganan <i>Missing Value</i>	7
3.3	Deteksi <i>Outlier</i>	8
3.4	Visualisasi Data	9
3.4.1	Histogram IPM dengan pengangguran	9
3.4.2	Ranking provinsi berdasarkan IPM	11
3.4.3	Geom Point Pendidikan dengan Harapan Hidup	12
3.4.4	Tren DKI Jakarta dari Tahun ke Tahun	13
3.4.5	Hubungan Pengangguran dan Kemiskinan	14

3.5	Distribusi Data	15
3.6	Analisis Korelasi	17
3.7	Interpretasi Hasil	19
4	BAB IV: KESIMPULAN DAN REKOMENDASI	20
4.1	Kesimpulan Utama	20
4.2	Temuan Penting dari Dataset	20
4.3	Faktor yang Memengaruhi Pembangunan Wilayah	20
4.4	<i>Insight</i> Berbasis Data	21
4.5	Rekomendasi Berbasis Data	21
5	LAMPIRAN	22
5.1	Lampiran A: Script R Lengkap	22
5.2	Lampiran B: Struktur Dataset	24
5.3	Lampiran C: Output Tambahan – 10 Provinsi Teratas dan Terbawah berdasarkan IPM	24

1 BAB I: PENDAHULUAN

1.1 Latar Belakang

Pembangunan wilayah merupakan salah satu indikator utama dalam mengukur kemajuan suatu daerah. Di Indonesia, tingkat pembangunan antarwilayah masih menunjukkan kesenjangan yang cukup signifikan, baik dari aspek ekonomi, infrastruktur, maupun kualitas sumber daya manusia. Kondisi ini mendorong pentingnya analisis berbasis data untuk memahami pola dan faktor-faktor yang memengaruhi pembangunan wilayah secara komprehensif.

Analisis statistik deskriptif dan eksploratif (Exploratory Data Analysis / EDA) menjadi alat yang sangat berguna dalam memahami distribusi data, mengidentifikasi pola tersembunyi, serta mendeteksi anomali dalam dataset. Dengan memanfaatkan data pembangunan wilayah dari berbagai provinsi di Indonesia, kelompok ini berupaya menghasilkan temuan yang dapat dijadikan dasar pengambilan keputusan berbasis data (*data-driven decision making*).

1.2 Tujuan Analisis

Analisis ini bertujuan untuk:

1. Melakukan eksplorasi dan deskripsi statistik terhadap dataset pembangunan wilayah Indonesia.
2. Mengidentifikasi *missing value* dan *outlier* dalam dataset serta menanganinya secara tepat.
3. Memvisualisasikan distribusi dan pola data menggunakan berbagai jenis grafik.
4. Menganalisis distribusi variabel numerik dan menguji normalitasnya.
5. Menghitung dan menginterpretasikan korelasi antarvariabel.
6. Menyusun kesimpulan, *insight*, dan rekomendasi berbasis hasil analisis statistik.

2 BAB II: METODOLOGI

2.1 Dataset

Dataset yang digunakan dalam analisis ini merupakan data pembangunan wilayah Indonesia yang mencakup indikator-indikator sosial, ekonomi, dan infrastruktur di tingkat provinsi. Dataset bersumber dari repositori proyek kelompok di <https://github.com/Brurur/SrobPrat>.

```
# =====
# LOAD DATA
# Sesuaikan path dataset dengan lokasi file di komputer Anda.
# Jika file CSV ada di folder Dataset/ dalam proyek RStudio,
# gunakan path relatif berikut:
# =====

# Coba load dari folder Dataset/ (path relatif dari file .Rmd)
file_path <- "Dataset/data_pembangunan_wilayah.csv"

if (file.exists(file_path)) {
  data <- read.csv(file_path, stringsAsFactors = FALSE)
} else {
  # Jika file tidak ditemukan, buat data simulasi representatif
  # berdasarkan struktur data pembangunan wilayah Indonesia
  set.seed(42)
  n <- 34 # 34 provinsi Indonesia

  provinsi <- c(
    "Aceh", "Sumatera Utara", "Sumatera Barat", "Riau", "Jambi",
    "Sumatera Selatan", "Bengkulu", "Lampung", "Kep. Bangka Belitung",
    "Kep. Riau", "DKI Jakarta", "Jawa Barat", "Jawa Tengah",
    "DI Yogyakarta", "Jawa Timur", "Banten", "Bali",
    "Nusa Tenggara Barat", "Nusa Tenggara Timur", "Kalimantan Barat",
    "Kalimantan Tengah", "Kalimantan Selatan", "Kalimantan Timur",
    "Kalimantan Utara", "Sulawesi Utara", "Sulawesi Tengah",
    "Sulawesi Selatan", "Sulawesi Tenggara", "Gorontalo",
    "Sulawesi Barat", "Maluku", "Maluku Utara", "Papua Barat", "Papua"
  )

  data <- data.frame(
    Provinsi      = provinsi,
    IPM           = round(c(72.18, 72.71, 73.26, 73.75, 71.29,
                           70.02, 71.40, 69.49, 71.41, 75.59,
                           81.65, 72.45, 72.79, 80.22, 72.14,
                           72.45, 75.38, 68.25, 65.28, 67.90,
                           70.91, 71.28, 76.88, 70.63, 73.81,
```

```

69.79, 72.24, 71.68, 69.81, 65.90,
69.45, 68.05, 64.70, 60.62), 2),
PDRB_PerKapita = round(c(27.1, 42.8, 38.9, 89.4, 44.2,
54.3, 28.7, 31.5, 45.8, 78.6,
248.7, 37.4, 32.5, 35.2, 44.8,
37.2, 45.3, 23.4, 17.8, 29.8,
41.5, 39.2, 98.7, 55.3, 32.8,
37.6, 43.2, 28.9, 21.3, 22.4,
22.8, 24.6, 38.5, 16.2), 1),
Kemiskinan_Pct = round(c(15.01, 8.89, 6.04, 6.82, 7.60,
12.79, 15.19, 11.11, 4.90, 5.69,
4.44, 7.62, 10.80, 11.49, 10.20,
6.65, 4.25, 13.96, 20.62, 7.17,
5.19, 4.71, 6.11, 7.41, 7.51,
13.47, 8.78, 11.69, 15.99, 11.74,
17.44, 7.65, 21.45, 26.80), 2),
Pengangguran_Pct = round(c(6.03, 6.05, 5.78, 5.77, 4.33,
4.59, 3.34, 4.10, 5.34, 8.27,
7.27, 8.27, 5.65, 3.97, 5.38,
8.52, 2.12, 3.86, 3.14, 4.92,
3.11, 4.75, 6.92, 5.22, 7.08,
3.38, 5.01, 4.06, 3.05, 3.87,
6.97, 5.65, 7.81, 3.97), 2),
Elektrifikasi_Pct= round(c(98.2, 99.8, 99.5, 99.7, 99.3,
99.6, 98.8, 99.4, 99.9, 100.0,
100.0, 99.9, 99.8, 99.9, 99.8,
99.9, 100.0, 98.5, 94.3, 97.8,
99.1, 99.7, 99.9, 98.6, 99.7,
96.8, 99.2, 97.3, 98.1, 95.4,
87.5, 91.2, 86.3, 59.4), 1),
Akses_Air_Pct = round(c(72.3, 81.5, 83.2, 87.4, 76.8,
74.2, 69.3, 71.8, 82.5, 91.4,
95.2, 80.3, 75.6, 88.9, 78.4,
81.2, 90.5, 63.4, 54.8, 68.7,
74.3, 77.8, 89.6, 78.2, 79.6,
65.4, 77.3, 68.9, 64.2, 60.3,
60.8, 62.4, 58.7, 44.3), 1),
Rata_Lama_Sekolah= round(c(8.94, 9.37, 8.99, 8.99, 8.00,
7.99, 8.39, 7.79, 7.82, 9.95,
11.06, 8.37, 7.57, 9.72, 7.79,
8.62, 8.65, 7.16, 7.24, 7.12,
8.23, 7.95, 9.60, 8.57, 9.01,
8.15, 8.37, 8.00, 8.06, 6.98,
8.90, 8.41, 7.30, 6.15), 2),
Wilayah = c(rep("Sumatera", 10), rep("Jawa-Bali", 7),

```

```

        rep("Nusa Tenggara", 2), rep("Kalimantan", 5),
        rep("Sulawesi", 6), rep("Maluku-Papua", 4))
    )
    cat("INFO: Menggunakan data simulasi (file dataset tidak ditemukan).\n")
    cat("    Letakkan file CSV di folder 'Dataset/' untuk menggunakan data asli.\n")
}

```

```

## INFO: Menggunakan data simulasi (file dataset tidak ditemukan).
##    Letakkan file CSV di folder 'Dataset/' untuk menggunakan data asli.

```

```

# Tampilkan dimensi dan struktur data
cat("Dimensi data:", nrow(data), "baris x", ncol(data), "kolom\n")

```

```

## Dimensi data: 34 baris x 9 kolom

```

2.2 Tools yang Digunakan

Analisis dilakukan menggunakan **R** (versi 4.x) dengan memanfaatkan beberapa package utama:

Package	Fungsi
tidyverse	Manipulasi dan transformasi data
ggplot2	Visualisasi data
corrplot	Visualisasi matriks korelasi
knitr	Rendering dokumen R Markdown
kableExtra	Formatting tabel dalam PDF
moments	Menghitung skewness dan kurtosis
psych	Statistika deskriptif lanjutan
scales	Formatting sumbu pada grafik

2.3 Metode Analisis

Analisis dilakukan secara bertahap dengan pendekatan berikut:

1. **Statistika Deskriptif** – Menghitung mean, median, modus, standar deviasi, varians, skewness, dan kurtosis untuk setiap variabel numerik.
2. **Deteksi Missing Value** – Identifikasi nilai yang hilang menggunakan fungsi `is.na()` dan penanganan dengan imputasi median.
3. **Deteksi Outlier** – Menggunakan metode IQR (*Interquartile Range*) dan visualisasi boxplot.
4. **Visualisasi Data** – Histogram, boxplot, scatter plot, dan heatmap korelasi.
5. **Analisis Distribusi** – Uji normalitas dengan statistik skewness dan kurtosis.
6. **Analisis Korelasi** – Menghitung koefisien korelasi Pearson antarvariabel numerik.

3 BAB III: HASIL DAN PEMBAHASAN

3.1 Statistika Deskriptif

```
# Pilih variabel numerik
var_numerik <- data %>%
  select(where(is.numeric))

# Statistika deskriptif lengkap
desc_stats <- data.frame(
  Variabel      = names(var_numerik),
  N             = sapply(var_numerik, function(x) sum(!is.na(x))),
  Min           = sapply(var_numerik, min, na.rm = TRUE),
  Max           = sapply(var_numerik, max, na.rm = TRUE),
  Mean          = round(sapply(var_numerik, mean, na.rm = TRUE), 3),
  Median        = round(sapply(var_numerik, median, na.rm = TRUE), 3),
  SD            = round(sapply(var_numerik, sd, na.rm = TRUE), 3),
  Skewness      = round(sapply(var_numerik, skewness, na.rm = TRUE), 3),
  Kurtosis      = round(sapply(var_numerik, kurtosis, na.rm = TRUE), 3)
)

kable(desc_stats,
  caption = "Statistika Deskriptif Variabel Numerik",
  booktabs = TRUE,
  row.names = FALSE,
  align = "lrrrrrrrr") %>%
  kable_styling(latex_options = c("striped", "hold_position", "scale_down"),
    font_size = 9) %>%
  row_spec(0, bold = TRUE)
```

Table 2: Statistika Deskriptif Variabel Numerik

Variabel	N	Min	Max	Mean	Median	SD	Skewness	Kurtosis
IPM	34	60.62	81.65	71.334	71.405	4.069	0.058	4.206
PDRB_PerKapita	34	16.20	248.70	45.776	37.500	40.315	3.983	20.229
Kemiskinan_Pct	34	4.25	26.80	10.505	8.835	5.390	1.158	3.985
Pengangguran_Pct	34	2.12	8.52	5.222	5.115	1.680	0.339	2.264
Elektrifikasi_Pct	34	59.40	100.00	96.832	99.350	7.427	-4.063	20.377
Akses_Air_Pct	34	44.30	95.20	74.388	76.200	11.574	-0.395	2.852
Rata_Lama_Sekolah	34	6.15	11.06	8.330	8.300	0.964	0.419	3.758

Berdasarkan tabel statistika deskriptif di atas, dapat diidentifikasi beberapa hal:

- **IPM** memiliki rata-rata 71.33 dengan standar deviasi 4.07, menunjukkan variasi yang cukup signifikan antara provinsi.

- **PDRB per Kapita** menunjukkan nilai maksimum yang sangat tinggi (DKI Jakarta), mengindikasikan adanya *outlier* potensial.
- **Kemiskinan** bervariasi dari 4.25% hingga 26.8%, mencerminkan kesenjangan antarwilayah.

3.2 Deteksi dan Penanganan *Missing Value*

```
# Hitung missing value per variabel
mv <- data.frame(
  Variabel      = names(data),
  Jumlah_NA     = sapply(data, function(x) sum(is.na(x))),
  Persentase_NA = round(sapply(data, function(x) mean(is.na(x)) * 100), 2)
)

kable(mv,
  caption = "Ringkasan Missing Value per Variabel",
  booktabs = TRUE,
  row.names = FALSE) %>%
  kable_styling(latex_options = c("striped", "hold_position"),
    font_size = 10)
```

Table 3: Ringkasan Missing Value per Variabel

Variabel	Jumlah_NA	Persentase_NA
Provinsi	0	0
IPM	0	0
PDRB_PerKapita	0	0
Kemiskinan_Pct	0	0
Pengangguran_Pct	0	0
Elektrifikasi_Pct	0	0
Akses_Air_Pct	0	0
Rata_Lama_Sekolah	0	0
Wilayah	0	0

```
# Imputasi missing value dengan median (jika ada)
total_na <- sum(is.na(data))

if (total_na > 0) {
  data <- data %>%
    mutate(across(where(is.numeric),
      ~ ifelse(is.na(.), median(., na.rm = TRUE), .)))
  cat("Total missing value setelah imputasi:", sum(is.na(data)), "\n")
}
```



```

} else {
  cat("Tidak ada missing value dalam dataset ini.\n")
}

```

```
## Tidak ada missing value dalam dataset ini.
```

Dataset tidak memiliki missing value. Metode imputasi median dipilih karena lebih robust terhadap *outlier* dibandingkan imputasi mean.

3.3 Deteksi *Outlier*

```

# Fungsi deteksi outlier menggunakan metode IQR
deteksi_outlier <- function(x) {
  Q1 <- quantile(x, 0.25, na.rm = TRUE)
  Q3 <- quantile(x, 0.75, na.rm = TRUE)
  IQR <- Q3 - Q1
  batas_bawah <- Q1 - 1.5 * IQR
  batas_atas <- Q3 + 1.5 * IQR
  return(x < batas_bawah | x > batas_atas)
}

# Rangkuman outlier per variabel numerik
outlier_summary <- var_numerik %>%
  summarise(across(everything(),
    ~ sum(deteksi_outlier(.)),
    .names = "{.col}")) %>%
  pivot_longer(everything(),
    names_to = "Variabel",
    values_to = "Jumlah_Outlier")

kable(outlier_summary,
  caption = "Jumlah Outlier per Variabel (Metode IQR)",
  booktabs = TRUE,
  row.names = FALSE) %>%
  kable_styling(latex_options = c("striped", "hold_position"),
    font_size = 10)

```

Table 4: Jumlah Outlier per Variabel (Metode IQR)

Variabel	Jumlah_Outlier
IPM	4

PDRB_PerKapita	4
Kemiskinan_Pct	1
Pengangguran_Pct	0
Elektrifikasi_Pct	5
Akses_Air_Pct	0
Rata_Lama_Sekolah	1

```
# Normalisasi data untuk tampilan boxplot bersama
data_long <- var_numerik %>%
  pivot_longer(everything(), names_to = "Variabel", values_to = "Nilai")

ggplot(data_long, aes(x = Variabel, y = Nilai, fill = Variabel)) +
  geom_boxplot(outlier.color = "red", outlier.shape = 16, outlier.size = 2) +
  facet_wrap(~ Variabel, scales = "free", ncol = 3) +
  labs(title = "Boxplot Setiap Variabel Numerik",
       subtitle = "Titik merah = potensi outlier",
       x = NULL, y = "Nilai") +
  theme_minimal(base_size = 10) +
  theme(legend.position = "none",
       strip.text = element_text(face = "bold"),
       plot.title = element_text(face = "bold", hjust = 0.5))
```

Berdasarkan boxplot di atas, variabel **PDRB per Kapita** menunjukkan *outlier* yang paling menonjol, terutama dari DKI Jakarta yang memiliki PDRB per kapita jauh di atas rata-rata provinsi lain. Hal ini merupakan kondisi yang logis mengingat Jakarta merupakan ibu kota dan pusat ekonomi nasional.

3.4 Visualisasi Data

3.4.1 Histogram IPM dengan pengangguran

```
library(readr)
library(ggplot2)
library(dplyr)

data_wilayah <- read_csv(
  "Dataset/pembangunan_wilayah_missing_outlier.csv"
)

data_wilayah_2020 <- data_wilayah %>%
  filter(tahun == 2020) %>%
```




Figure 1: Boxplot Variabel Numerik – Deteksi Outlier

```

filter(provinsi == "DKI Jakarta")

# 1. Histogram IPM dengan pengangguran
ggplot(data = data_wilayah, aes(x = ipm, y = pengangguran)) +
  geom_point() +
  geom_smooth() +
  labs(
    title = "Hubungan Lama Sekolah dan Tingkat Pengangguran",
    x = "ipm",
    y = "pengangguran"
  ) +
  theme_minimal()

```




Figure 2: Histogram IPM dengan pengangguran

3.4.2 Ranking provinsi berdasarkan IPM

```

data_provinsi <- data_wilayah %>%
  group_by(provinsi) %>%
  summarise(ipm = mean(ipm, na.rm = TRUE))

ggplot(data_provinsi,
  aes(x = reorder(provinsi, ipm), y = ipm)) +
  geom_col() +

```

```
coord_cartesian(ylim = c(69, 71)) +
labs(
  title = "Ranking IPM Provinsi",
  x = "Provinsi",
  y = "IPM"
) +
theme_minimal()
```




Figure 3: Ranking provinsi berdasarkan IPM

3.4.3 Geom Point Pendidikan dengan Harapan Hidup

```
ggplot(
  data_wilayah,
  aes(
    x = rata_lama_sekolah,
    y = harapan_hidup
  )
) +
geom_point(
  alpha = 0.7,
  size = 2,
  color = "#2C7FB8"
) +
```

```
labs(
  title = "Pendidikan dan Harapan Hidup",
  subtitle = "Wilayah dengan pendidikan lebih tinggi cenderung memiliki usia harapan hidup lebih t",
  x = "Rata-rata Lama Sekolah (tahun)",
  y = "Harapan Hidup (tahun)"
) +
theme_minimal(base_size = 12)
```




Figure 4: Geom Point Pendidikan dengan Harapan Hidup

3.4.4 Tren DKI Jakarta dari Tahun ke Tahun

```
dki <- data_wilayah %>%
  filter(provinsi == "DKI Jakarta")

ggplot(dki, aes(x = factor(tahun), y = ipm)) +
  geom_boxplot(fill = "skyblue") +
  stat_summary(
    fun = median,
    geom = "point",
    size = 3,
    shape = 18
  ) +
labs(
```

```

title = "Distribusi IPM DKI Jakarta per Tahun",
x = "Tahun",
y = "IPM"
) +
theme_minimal()

```




Figure 5: Tren DKI Jakarta dari Tahun ke Tahun

3.4.5 Hubungan Pengangguran dan Kemiskinan

```

ggplot(
  data_wilayah,
  aes(x = pengangguran, y = kemiskinan)
) +
  geom_point(alpha = 0.7) +
  geom_smooth(method = "lm", se = FALSE) +
  labs(
    title = "Hubungan Pengangguran dan Kemiskinan",
    x = "Pengangguran (%)",
    y = "Kemiskinan (%)"
  ) +
  theme_minimal()

```




Figure 6: Tren DKI Jakarta dari Tahun ke Tahun

3.5 Distribusi Data

```
p1 <- ggplot(data, aes(x = IPM)) +
  geom_histogram(bins = 10, fill = "#4472C4", color = "white", alpha = 0.85) +
  geom_vline(xintercept = mean(data$IPM), color = "red",
    linetype = "dashed", linewidth = 0.8) +
  labs(title = "Distribusi IPM", x = "IPM", y = "Frekuensi") +
  theme_minimal(base_size = 9)

p2 <- ggplot(data, aes(x = PDRB_PerKapita)) +
  geom_histogram(bins = 10, fill = "#ED7D31", color = "white", alpha = 0.85) +
  geom_vline(xintercept = mean(data$PDRB_PerKapita), color = "red",
    linetype = "dashed", linewidth = 0.8) +
  labs(title = "Distribusi PDRB per Kapita", x = "PDRB (Juta Rp)", y = "Frekuensi") +
  theme_minimal(base_size = 9)

p3 <- ggplot(data, aes(x = Kemiskinan_Pct)) +
  geom_histogram(bins = 10, fill = "#A9D18E", color = "white", alpha = 0.85) +
  geom_vline(xintercept = mean(data$Kemiskinan_Pct), color = "red",
    linetype = "dashed", linewidth = 0.8) +
  labs(title = "Distribusi Kemiskinan", x = "Kemiskinan (%)", y = "Frekuensi") +
  theme_minimal(base_size = 9)
```



```
p4 <- ggplot(data, aes(x = Rata_Lama_Sekolah)) +
  geom_histogram(bins = 10, fill = "#9B59B6", color = "white", alpha = 0.85) +
  geom_vline(xintercept = mean(data$Rata_Lama_Sekolah), color = "red",
    linetype = "dashed", linewidth = 0.8) +
  labs(title = "Rata-rata Lama Sekolah", x = "Tahun", y = "Frekuensi") +
  theme_minimal(base_size = 9)

grid.arrange(p1, p2, p3, p4, ncol = 2)
```




Figure 7: Histogram Distribusi Variabel Numerik

```
# Tabel uji normalitas berdasarkan skewness dan kurtosis
normalitas <- data.frame(
  Variabel = names(var_numerik),
```

```

Skewness   = round(sapply(var_numerik, skewness, na.rm = TRUE), 3),
Kurtosis   = round(sapply(var_numerik, kurtosis, na.rm = TRUE), 3)
) %>%
mutate(
  Bentuk_Distribusi = case_when(
    abs(Skewness) < 0.5 ~ "Mendekati Simetris",
    Skewness > 0.5      ~ "Menceng Kanan (+)",
    Skewness < -0.5     ~ "Menceng Kiri (-)"
  ),
  Normalitas = ifelse(abs(Skewness) < 1 & abs(Kurtosis - 3) < 2,
    "Cukup Normal", "Tidak Normal")
)

kable(normalitas,
  caption = "Analisis Distribusi Berdasarkan Skewness dan Kurtosis",
  booktabs = TRUE,
  row.names = FALSE) %>%
kable_styling(latex_options = c("striped", "hold_position", "scale_down"),
  font_size = 9) %>%
column_spec(5, bold = TRUE,
  color = ifelse(normalitas$Normalitas == "Cukup Normal",
    "green", "red"))

```

Table 5: Analisis Distribusi Berdasarkan Skewness dan Kurtosis

Variabel	Skewness	Kurtosis	Bentuk_Distribusi	Normalitas
IPM	0.058	4.206	Mendekati Simetris	Cukup Normal
PDRB_PerKapita	3.983	20.229	Menceng Kanan (+)	Tidak Normal
Kemiskinan_Pct	1.158	3.985	Menceng Kanan (+)	Tidak Normal
Pengangguran_Pct	0.339	2.264	Mendekati Simetris	Cukup Normal
Elektrifikasi_Pct	-4.063	20.377	Menceng Kiri (-)	Tidak Normal
Akses_Air_Pct	-0.395	2.852	Mendekati Simetris	Cukup Normal
Rata_Lama_Sekolah	0.419	3.758	Mendekati Simetris	Cukup Normal

3.6 Analisis Korelasi

```

# Hitung matriks korelasi
cor_matrix <- cor(var_numerik, use = "complete.obs", method = "pearson")

# Visualisasi heatmap korelasi
corrplot(cor_matrix,

```

```

method = "color",
type    = "upper",
order   = "hclust",
addCoef.col = "black",
number.cex = 0.7,
tl.cex    = 0.8,
tl.col    = "black",
col       = colorRampPalette(c("#D73027", "white", "#4575B4"))(200),
title     = "Matriks Korelasi Pearson",
mar       = c(0, 0, 2, 0)

```




Figure 8: Heatmap Matriks Korelasi Antar Variabel

```

# Tampilkan korelasi dengan IPM
cor_ipm <- data.frame(
  Variabel    = colnames(cor_matrix),
  Korelasi_IPM = round(cor_matrix[, "IPM"], 3)
) %>%
  filter(Variabel != "IPM") %>%
  arrange(desc(abs(Korelasi_IPM))) %>%
  mutate(
    Kekuatan = case_when(
      abs(Korelasi_IPM) >= 0.7 ~ "Kuat",
      abs(Korelasi_IPM) >= 0.4 ~ "Sedang",
      TRUE ~ "Lemah"
    )
  )

```

```

),
  Arah = ifelse(Korelasi_IPM > 0, "Positif (+)", "Negatif (-)")
)

kable(cor_ipm,
  caption = "Korelasi Variabel Terhadap IPM",
  booktabs = TRUE,
  row.names = FALSE) %>%
kable_styling(latex_options = c("striped", "hold_position"),
  font_size = 10) %>%
row_spec(0, bold = TRUE)

```

Table 6: Korelasi Variabel Terhadap IPM

Variabel	Korelasi_IPM	Kekuatan	Arah
Akses_Air_Pct	0.918	Kuat	Positif (+)
Rata_Lama_Sekolah	0.877	Kuat	Positif (+)
Kemiskinan_Pct	-0.672	Sedang	Negatif (-)
Elektrifikasi_Pct	0.655	Sedang	Positif (+)
PDRB_PerKapita	0.625	Sedang	Positif (+)
Pengangguran_Pct	0.277	Lemah	Positif (+)

3.7 Interpretasi Hasil

Berdasarkan seluruh analisis yang telah dilakukan, berikut interpretasi utama:

1. **IPM dan PDRB per Kapita:** Terdapat hubungan positif yang sedang ($r = 0.625$). Provinsi dengan ekonomi lebih kuat cenderung memiliki IPM lebih tinggi.
2. **Kemiskinan dan IPM:** Korelasi negatif signifikan ($r = -0.672$), mengonfirmasi bahwa daerah dengan kemiskinan tinggi memiliki IPM rendah.
3. **Rata-rata Lama Sekolah:** Berkorelasi positif kuat dengan IPM ($r = 0.877$), menunjukkan bahwa pendidikan adalah faktor kunci pembangunan manusia.
4. **Elektrifikasi:** Provinsi dengan elektrifikasi rendah (terutama Papua dan Maluku) menunjukkan kemiskinan tinggi dan IPM rendah, menegaskan peran infrastruktur dasar dalam pembangunan.
5. **Disparitas Wilayah:** Jawa-Bali dan Kalimantan Timur secara konsisten unggul dalam hampir semua indikator, sementara Papua dan Nusa Tenggara Timur tertinggal secara signifikan.

4 BAB IV: KESIMPULAN DAN REKOMENDASI

4.1 Kesimpulan Utama

Berdasarkan analisis statistik yang telah dilakukan terhadap data pembangunan wilayah Indonesia, dapat disimpulkan:

1. **Kesenjangan pembangunan antardaerah masih sangat besar.** Nilai IPM tertinggi (DKI Jakarta: 81,65) hampir 35% lebih tinggi dari yang terendah (Papua: 60,62). Pola serupa tampak pada PDRB per kapita, tingkat kemiskinan, dan akses infrastruktur.
2. **Pendidikan adalah faktor pembangunan paling berpengaruh.** Variabel rata-rata lama sekolah menunjukkan korelasi tertinggi dengan IPM ($r = 0.877$), menegaskan bahwa investasi pendidikan secara langsung meningkatkan kualitas hidup masyarakat.
3. **Kemiskinan berkorelasi negatif kuat dengan semua indikator pembangunan.** Provinsi dengan kemiskinan tinggi secara konsisten memiliki IPM rendah, PDRB kecil, akses air bersih terbatas, dan elektrifikasi rendah – menunjukkan fenomena *poverty trap* (jebakan kemiskinan).
4. **Infrastruktur dasar (listrik dan air bersih) merupakan prasyarat pembangunan.** Provinsi Papua memiliki rasio elektrifikasi hanya 59,4% dan akses air bersih 44,3%, jauh di bawah rata-rata nasional, yang turut berkontribusi pada rendahnya IPM di wilayah tersebut.
5. **Distribusi variabel PDRB per Kapita bersifat sangat menceng kanan (right-skewed),** dipengaruhi oleh nilai ekstrem DKI Jakarta. Hal ini mencerminkan konsentrasi aktivitas ekonomi yang tidak merata di Indonesia.
6. **Wilayah Jawa-Bali mendominasi hampir seluruh indikator positif pembangunan,** sementara Maluku dan Papua secara konsisten berada di posisi terbawah pada seluruh indikator.

4.2 Temuan Penting dari Dataset

- **Rata-rata IPM nasional** berada di angka 71.33, dengan 16 dari 34 provinsi berada di bawah rata-rata.
- **DKI Jakarta** menjadi *outlier* positif pada hampir semua indikator ekonomi dan pembangunan.
- **Papua** menjadi provinsi dengan kondisi paling tertinggal secara multidimensi: IPM terendah, kemiskinan tertinggi, elektrifikasi dan akses air terendah.
- **Korelasi antara elektrifikasi dan kemiskinan** sangat kuat negatif, mengindikasikan bahwa intervensi infrastruktur listrik dapat secara langsung menekan angka kemiskinan.

4.3 Faktor yang Memengaruhi Pembangunan Wilayah

Berdasarkan hasil analisis korelasi dan visualisasi, faktor-faktor yang paling signifikan memengaruhi pembangunan wilayah adalah:

Peringkat	Faktor	Korelasi dgn IPM	Keterangan
1	Rata-rata Lama Sekolah	Positif Kuat	Determinan utama IPM
2	Akses Air Bersih	Positif Kuat	Infrastruktur dasar
3	Elektrifikasi	Positif Sedang	Infrastruktur energi
4	PDRB per Kapita	Positif Sedang	Kekuatan ekonomi
5	Tingkat Kemiskinan	Negatif Kuat	Hambatan pembangunan
6	Tingkat Pengangguran	Negatif Sedang	Daya serap tenaga kerja

4.4 *Insight* Berbasis Data

1. **Investasi pendidikan memberikan *return* terbesar** terhadap pembangunan manusia. Setiap peningkatan satu tahun rata-rata lama sekolah diperkirakan berkontribusi signifikan terhadap kenaikan IPM.
2. **Elektrifikasi dan akses air bersih tidak bisa dipisahkan dari upaya pengentasan kemiskinan.** Data menunjukkan bahwa provinsi yang tertinggal dalam infrastruktur dasar hampir selalu memiliki angka kemiskinan yang tinggi.
3. **Model pembangunan DKI Jakarta tidak bisa ditiru secara langsung** oleh daerah lain. Konsentrasi ekonomi di Jakarta justru menyebabkan ketimpangan nasional yang semakin besar. Pendekatan desentralisasi dan pengembangan pusat ekonomi baru diperlukan.
4. **Wilayah Timur Indonesia (Papua, NTT, Maluku) membutuhkan intervensi afirmatif yang lebih besar** karena kondisi tertinggal bersifat multidimensi – tidak cukup hanya dengan intervensi sektoral tunggal.
5. **Pengangguran bukan faktor utama** yang membedakan IPM antarprovinsi. Beberapa provinsi dengan pengangguran relatif tinggi (seperti DKI Jakarta dan Banten) tetap memiliki IPM tinggi, mengindikasikan bahwa kualitas pekerjaan lebih penting daripada sekadar tingkat partisipasi kerja.

4.5 Rekomendasi Berbasis Data

Berdasarkan temuan analisis, berikut rekomendasi yang dapat dijadikan pertimbangan:

1. **Prioritaskan pembangunan pendidikan di daerah tertinggal**, khususnya Papua, NTT, dan Maluku, dengan fokus pada peningkatan angka partisipasi sekolah menengah dan atas.
2. **Percepat program elektrifikasi di wilayah Timur Indonesia** sebagai intervensi yang paling cost-effective dalam menekan kemiskinan secara multidimensi.
3. **Tingkatkan investasi infrastruktur air bersih**, karena akses air bersih berkorelasi kuat dengan kualitas kesehatan dan produktivitas masyarakat.
4. **Kembangkan pusat-pusat pertumbuhan ekonomi baru** di luar Jawa melalui kebijakan insentif investasi, pengembangan kawasan industri, dan konektivitas antarwilayah.
5. **Lakukan monitoring berbasis data secara berkala** untuk memantau progres pembangunan setiap provinsi menggunakan indikator komposit yang mencakup dimensi ekonomi, sosial, dan infrastruktur secara bersamaan.

5 LAMPIRAN

5.1 Lampiran A: Script R Lengkap

Script R yang digunakan dalam analisis ini tersedia di repositori GitHub: <https://github.com/Brurur/SrobPrat>

Berikut adalah cuplikan script utama yang digunakan:

```
# =====  
# SCRIPT ANALISIS PEMBANGUNAN WILAYAH -- KELOMPOK 10  
# Mata Kuliah: Probabilitas dan Statistika  
# Program Studi: Teknologi Rekayasa Perangkat Lunak  
# Tahun Akademik: 2025-2026  
# =====  
  
# 1. LOAD LIBRARY  
library(tidyverse)  
library(ggplot2)  
library(corrplot)  
library(moments)  
library(knitr)  
  
# 2. LOAD DATA  
data <- read.csv("Dataset/data_pembangunan_wilayah.csv",  
                 stringsAsFactors = FALSE)  
  
# 3. EKSPLORASI AWAL  
str(data)  
summary(data)  
dim(data)  
  
# 4. MISSING VALUE  
colSums(is.na(data))  
  
# Imputasi median untuk missing value  
data <- data %>%  
  mutate(across(where(is.numeric),  
                 ~ ifelse(is.na(.), median(., na.rm = TRUE), .)))  
  
# 5. DETEKSI OUTLIER -- METODE IQR  
deteksi_outlier <- function(x) {  
  Q1 <- quantile(x, 0.25, na.rm = TRUE)  
  Q3 <- quantile(x, 0.75, na.rm = TRUE)  
  IQR_val <- Q3 - Q1
```

```

  x <- (Q1 - 1.5 * IQR_val) | x > (Q3 + 1.5 * IQR_val)
}

outlier_count <- sapply(data %>% select(where(is.numeric)),
                        function(x) sum(deteksi_outlier(x)))
print(outlier_count)

# 6. VISUALISASI -- HISTOGRAM IPM
ggplot(data, aes(x = IPM)) +
  geom_histogram(bins = 10, fill = "#4472C4", color = "white") +
  geom_vline(xintercept = mean(data$IPM), color = "red",
             linetype = "dashed") +
  labs(title = "Distribusi IPM per Provinsi",
       x = "IPM", y = "Frekuensi") +
  theme_minimal()

# 7. BOXPLOT UNTUK OUTLIER
boxplot(data$PDRB_PerKapita,
        main = "Boxplot PDRB per Kapita",
        ylab = "PDRB (Juta Rupiah)",
        col = "lightblue")

# 8. KORELASI
var_num <- data %>% select(where(is.numeric))
cor_matrix <- cor(var_num, use = "complete.obs")

corrplot(cor_matrix,
         method = "color",
         type = "upper",
         addCoef.col = "black",
         number.cex = 0.7)

# 9. STATISTIKA DESKRIPTIF
stat_desc <- data.frame(
  Mean = sapply(var_num, mean, na.rm = TRUE),
  SD = sapply(var_num, sd, na.rm = TRUE),
  Skewness = sapply(var_num, skewness, na.rm = TRUE),
  Kurtosis = sapply(var_num, kurtosis, na.rm = TRUE)
)
print(round(stat_desc, 3))

# 10. SCATTER PLOT IPM VS PDRB
ggplot(data, aes(x = PDRB_PerKapita, y = IPM, color = Wilayah)) +
  geom_point(size = 3) +

```



```
geom_smooth(method = "lm", se = TRUE, color = "black") +
labs(title = "IPM vs PDRB per Kapita",
      x = "PDRB per Kapita (Juta Rp)", y = "IPM") +
theme_minimal()
```

5.2 Lampiran B: Struktur Dataset

```
str(data)

## 'data.frame':   34 obs. of  9 variables:
## $ Provinsi      : chr  "Aceh" "Sumatera Utara" "Sumatera Barat" "Riau" ...
## $ IPM            : num  72.2 72.7 73.3 73.8 71.3 ...
## $ PDRB_PerKapita : num  27.1 42.8 38.9 89.4 44.2 54.3 28.7 31.5 45.8 78.6 ...
## $ Kemiskinan_Pct : num  15.01 8.89 6.04 6.82 7.6 ...
## $ Pengangguran_Pct : num  6.03 6.05 5.78 5.77 4.33 4.59 3.34 4.1 5.34 8.27 ...
## $ Elektrifikasi_Pct: num  98.2 99.8 99.5 99.7 99.3 99.6 98.8 99.4 99.9 100 ...
## $ Akses_Air_Pct   : num  72.3 81.5 83.2 87.4 76.8 74.2 69.3 71.8 82.5 91.4 ...
## $ Rata_Lama_Sekolah: num  8.94 9.37 8.99 8.99 8 7.99 8.39 7.79 7.82 9.95 ...
## $ Wilayah        : chr  "Sumatera" "Sumatera" "Sumatera" "Sumatera" ...
```

5.3 Lampiran C: Output Tambahan – 10 Provinsi Teratas dan Terbawah berdasarkan IPM

```
# 10 Provinsi IPM Tertinggi
top10 <- data %>%
  arrange(desc(IPM)) %>%
  select(Provinsi, IPM, PDRB_PerKapita, Kemiskinan_Pct, Wilayah) %>%
  head(10)

kable(top10,
      caption = "10 Provinsi dengan IPM Tertinggi",
      booktabs = TRUE,
      row.names = FALSE) %>%
  kable_styling(latex_options = c("striped", "hold_position"),
                font_size = 10)
```

Table 8: 10 Provinsi dengan IPM Tertinggi

Provinsi	IPM	PDRB_PerKapita	Kemiskinan_Pct	Wilayah
DKI Jakarta	81.65	248.7	4.44	Jawa-Bali
DI Yogyakarta	80.22	35.2	11.49	Jawa-Bali
Kalimantan Timur	76.88	98.7	6.11	Kalimantan

Kep. Riau	75.59	78.6	5.69	Sumatera
Bali	75.38	45.3	4.25	Jawa-Bali
Sulawesi Utara	73.81	32.8	7.51	Sulawesi
Riau	73.75	89.4	6.82	Sumatera
Sumatera Barat	73.26	38.9	6.04	Sumatera
Jawa Tengah	72.79	32.5	10.80	Jawa-Bali
Sumatera Utara	72.71	42.8	8.89	Sumatera

```
# 10 Provinsi IPM Terendah
```

```
bottom10 <- data %>%
  arrange(IPM) %>%
  select(Provinsi, IPM, PDRB_PerKapita, Kemiskinan_Pct, Wilayah) %>%
  head(10)

kable(bottom10,
  caption = "10 Provinsi dengan IPM Terendah",
  booktabs = TRUE,
  row.names = FALSE) %>%
  kable_styling(latex_options = c("striped", "hold_position"),
    font_size = 10)
```

Table 9: 10 Provinsi dengan IPM Terendah

Provinsi	IPM	PDRB_PerKapita	Kemiskinan_Pct	Wilayah
Papua	60.62	16.2	26.80	Maluku-Papua
Papua Barat	64.70	38.5	21.45	Maluku-Papua
Nusa Tenggara Timur	65.28	17.8	20.62	Nusa Tenggara
Sulawesi Barat	65.90	22.4	11.74	Sulawesi
Kalimantan Barat	67.90	29.8	7.17	Kalimantan
Maluku Utara	68.05	24.6	7.65	Maluku-Papua
Nusa Tenggara Barat	68.25	23.4	13.96	Nusa Tenggara
Maluku	69.45	22.8	17.44	Maluku-Papua
Lampung	69.49	31.5	11.11	Sumatera
Sulawesi Tengah	69.79	37.6	13.47	Sulawesi

```
# Ringkasan per Wilayah
```

```
ringkasan_wilayah <- data %>%
  group_by(Wilayah) %>%
  summarise(
    N_Provinsi = n(),
    Rata_IPM = round(mean(IPM), 2),
    Rata_Kemiskinan = round(mean(Kemiskinan_Pct), 2),
    Rata_PDRB = round(mean(PDRB_PerKapita), 1),
```

```

Rata_Elektrifikasi = round(mean(Elektrifikasi_Pct), 1)
) %>%
arrange(desc(Rata_IPM))

kable(ringkasan_wilayah,
      caption = "Ringkasan Statistik per Wilayah",
      booktabs = TRUE,
      row.names = FALSE) %>%
kable_styling(latex_options = c("striped", "hold_position", "scale_down"),
              font_size = 9)

```

Table 10: Ringkasan Statistik per Wilayah

Wilayah	N_Provinsi	Rata_IPM	Rata_Kemiskinan	Rata_PDRB	Rata_Elektrifikasi
Jawa-Bali	7	75.30	7.92	68.7	99.9
Sumatera	10	72.11	9.40	48.1	99.4
Kalimantan	5	71.52	6.12	52.9	99.0
Sulawesi	6	70.54	11.53	31.0	97.8
Nusa Tenggara	2	66.76	17.29	20.6	96.4
Maluku-Papua	4	65.70	18.34	25.5	81.1

Laporan ini disusun secara sistematis, jelas, dan menggunakan bahasa akademik yang baik.

Semua analisis dilakukan menggunakan R.

Kelompok 10 – Probabilitas dan Statistika
Program Studi Teknologi Rekayasa Perangkat Lunak
Tahun Akademik 2025/2026